Guia de diagnóstico - Llama Desktop Launcher

Versão 0.9.0 · Português (Brasil)

Este guia ajuda a descobrir por que algo não funcionou: onde olhar, o que significam as mensagens do aplicativo, problemas comuns de cada motor e plataforma, e como montar um relatório para pedir ajuda. Para o uso normal, veja o **Manual de uso** (MANUAL-pt-BR); para clientes e API, o **Guia de integração** (INTEGRATION-pt-BR).

1. Por onde começar

1. **Leia a mensagem** que aparece abaixo dos botões (em vermelho quando é erro). As mais comuns estão na seção 10.
2. **Abra o Registro do motor** na tela **Llama** (acordeão abaixo dos botões). Ele mostra a saída do motor e as linhas [launcher] com o que o aplicativo tentou fazer. As últimas linhas antes de uma falha costumam dizer a causa: falta de memória, arquivo incompatível, porta ocupada, driver ausente.
3. **Copie o relatório de diagnóstico** em **Configurações > 06 · Diagnóstico** (seção 3) se for pedir ajuda.

O registro fica **só na memória** enquanto o launcher está aberto: a janela mostra os últimos 30 mil caracteres e o relatório leva os últimos 12 mil. Não há arquivo de log em disco. Copie o relatório **antes** de fechar o aplicativo.

2. Onde ficam os dados

Sistema	Pasta de dados do aplicativo
Windows	%APPDATA%\Llama Desktop Launcher
Linux	~/.config/Llama Desktop Launcher
macOS	~/Library/Application Support/Llama Desktop Launcher

Item	Onde fica
Preferências, pastas e perfis	settings.json na pasta de dados
Chave permanente da API	server-api-key.txt na pasta de dados (não envie a ninguém)
llama.cpp baixado	engines/ na pasta de dados, um subdiretório por download
vLLM no Linux	engines/vllm-0.32.0-… na pasta de dados (ou o ambiente que você escolheu)
vLLM no Windows	Imagem vllm/vllm-openai:v0.32.0 no Docker Desktop; contêineres llama-desktop-vllm-…
Strata / PolyStrata	A pasta onde o instalador deles foi executado
Pacotes de atualização	updates/ na pasta de dados
Modelos	As pastas escolhidas em **02 · Pastas**

O caminho de cada motor também aparece em **Configurações**. Se o settings.json estiver corrompido, o aplicativo volta à configuração padrão e sobrescreve o arquivo. Faça uma cópia antes de editar à mão.

3. Relatório de diagnóstico

Em **Configurações > 06 · Diagnóstico**, clique em **Copiar relatório de diagnóstico**. O texto vai para a área de transferência e aparece logo abaixo do botão para você revisar.

O relatório traz:

- versão do launcher, do Electron e do Node, sistema operacional e arquitetura;
- CPU, RAM, GPU e VRAM detectadas;
- estado de cada motor (pronto, pendente ou indisponível), versão, modo e caminho, além do backend e da release do llama.cpp e do estado do Docker no Windows;
- pastas de modelos (e se existem), quantidade de modelos por motor, modelo selecionado e o perfil dele;
- endereço e sessões escolhidos, servidor ativo (motor, porta, ID do modelo, contexto, compartilhamento);
- estado da verificação de atualizações;
- os últimos 12 mil caracteres do Registro do motor.

Antes de copiar, o aplicativo **remove** a chave permanente da API, a credencial de compartilhamento, cabeçalhos Bearer, parâmetros token=, variáveis como *_API_KEY e *_TOKEN, tokens do Hugging Face (hf_…) e troca a sua pasta pessoal por ~. Mesmo assim, **leia o texto antes de enviar**: nomes de modelos, IPs da rede interna e trechos de prompts no registro continuam visíveis.

Para pedir ajuda, abra uma issue no GitHub com o relatório, o que você fez e o que esperava. Nunca publique a chave da API nem links com acesso.

Se o aplicativo não abre

Monte o relatório à mão: sistema e versão, versão do launcher (nome do instalador), como instalou (EXE, DEB, RPM, AppImage, DMG) e a mensagem exibida. No Linux, abra pelo terminal (llama-desktop-launcher ou a AppImage) para ver as mensagens de erro. Se o problema começou depois de mexer em settings.json, renomeie o arquivo e abra de novo.

4. Problemas gerais

Sintoma	O que fazer
A lista de modelos está vazia	Confira as pastas em **02 · Pastas** e clique em **Atualizar lista**. GGUF precisa terminar em .gguf; vLLM precisa de config.json e .safetensors na mesma pasta; Strata precisa da pasta instalada escolhida em **01B**.
O aplicativo sempre abre em Configurações	Falta um motor pronto, um modelo nas pastas ou um modelo selecionado. Selecione um modelo na tela **Llama** ou clique em **Concluir e ir para Llama**.
Os botões de iniciar ficam desabilitados	O motor do modelo selecionado não está pronto (veja o selo em **Configurações**) ou já existe uma execução. Pare o servidor, a conversa ou o teste.
“Conversar aqui” e “Abrir CLI” desabilitados	São só para GGUF no llama.cpp. Com vLLM ou Strata, use **Iniciar servidor** e um cliente.
A pasta de modelos é recusada	Ela não pode ficar dentro da instalação nem da pasta de dados do aplicativo.
GPU ou VRAM aparecem como “não medida”	O sistema não informou um valor confiável. As sugestões usam só a RAM; ajuste à mão.

5. llama.cpp

Sintoma	Causa provável e solução
Download do motor falha	Sem internet, sem espaço ou GitHub bloqueado. Tente de novo ou use **Escolher pasta existente** com um motor baixado à mão.
“A versão … não contém todos os pacotes de …”	A release não tem esse backend para a sua plataforma. Escolha outro backend.
“Checksum SHA-256 do download não confere”	Download corrompido ou interceptado. Tente de novo em outra rede.
“O pacote CUDA não contém as bibliotecas esperadas” / “Pacote baixado sem llama-server”	O formato da release mudou. Escolha outro backend ou uma pasta existente e relate o problema.
“O motor encerrou antes de ficar pronto.”	Veja o fim do Registro do motor. Em geral: memória insuficiente (reduza contexto, batch ou camadas na GPU, ou use cache q8_0), GGUF incompatível com b12211, shards faltando ou driver ausente.
“Tempo esgotado ao carregar o modelo.”	O llama.cpp tem 5 minutos para carregar. Use um modelo menor, um disco mais rápido ou menos contexto.
A GPU não é usada	Confira o backend (CUDA para NVIDIA, Vulkan para qualquer GPU), o driver e o campo **Camadas na GPU** (auto ou all). O registro mostra quantas camadas foram para a GPU.
CUDA não carrega no Windows	Atualize o driver NVIDIA. Se continuar, teste o backend Vulkan.
“Este pacote não inclui llama-bench.” / benchmark falha	Use um pacote oficial com llama-bench ou ajustes mais conservadores. O teste tem limite de 10 minutos.
“Não encontrei um terminal gráfico.” (Linux)	Instale um terminal como gnome-terminal ou xterm para usar **Abrir CLI no terminal**.
“Este pacote do llama.cpp não inclui llama-fit-params.”	Pacote antigo ou incompleto. Baixe o motor oficial de novo. Sem ele, os valores automáticos não aparecem, mas o servidor funciona.
Autotuning: tentativa com “não coube na memória” ou “failed to allocate”	Normal: aquela combinação passa do limite da GPU e foi descartada. O resultado usa as que couberam.
Autotuning: “Divisão entre GPUs: row” falha	O backend (Vulkan, por exemplo) não suporta -sm row. A tentativa é descartada.
Autotuning muda pouco ou nada	Um valor só troca o atual com ganho de pelo menos 2%. Com orçamento curto, a busca para antes de testar tudo; a tabela **Medições do autotuning** mostra o que foi testado.
“Este modelo não tem camadas MTP (draft-mtp).”	O GGUF não tem camadas NextN/MTP. Escolha outro tipo de decodificação especulativa ou deixe em Auto.
“Cache V quantizado exige Flash Attention ligado ou automático.”	Ligue Flash Attention ou use cache V f16.
“Escolha o modelo rascunho para a decodificação especulativa.”	Os tipos draft-simple e draft-eagle3 precisam de um GGUF menor da mesma família nas pastas de modelos.
Um campo aparece em “Não se aplicam a este modelo”	O motivo aparece embaixo dele. Se o launcher não consegue ler o cabeçalho do GGUF, nada é escondido.

6. vLLM

Linux (ambiente Python)

Sintoma	Causa provável e solução
“Python 3 não encontrado.”	Instale python3 e python3-venv (Python 3.10 a 3.13), por exemplo sudo apt install python3 python3-venv.
“python falhou (1): …” durante a instalação	O pip falhou; o fim da mensagem e o registro mostram o motivo (rede, espaço, versão do Python sem wheel). A pasta incompleta é apagada; tente de novo.
“A pasta precisa conter bin/vllm.”	Em **Usar ambiente existente**, escolha a raiz do ambiente (a pasta que contém bin/).
Erro de CUDA ou “no GPU” ao iniciar	O pacote do pip é só para NVIDIA. Confira nvidia-smi. Para AMD, instale o vLLM com ROCm pela documentação oficial e aponte esse ambiente.
Falta de memória da GPU	Reduza o **Contexto** (--max-model-len) e as **Sessões simultâneas** (--max-num-seqs), ou use um modelo quantizado (AWQ, GPTQ).

Windows (Docker Desktop)

Sintoma	Causa provável e solução
“Docker Desktop não encontrado ou parado.”	Instale o Docker Desktop com WSL2, abra-o, espere ficar pronto e clique em **Verificar de novo**.
O download da imagem falha	Precisa de cerca de 10 GB livres no disco do WSL e internet estável. Tente de novo; o docker pull continua de onde parou.
O contêiner não vê a GPU	Ative a GPU no WSL2 conforme a documentação do Docker e atualize o driver NVIDIA do Windows.
“Os pesos deste modelo são links simbólicos…”	A pasta aponta para arquivos fora dela. Use uma pasta com os arquivos reais ou o layout do cache do Hugging Face (models--org--nome/snapshots/<hash>).
“O caminho do modelo não pode conter vírgulas…”	Renomeie a pasta ou mova o modelo para um caminho sem vírgulas.
O modelo pede download ou falta arquivo	O contêiner roda sem internet (HF_HUB_OFFLINE=1). Baixe o repositório completo (inclusive tokenizer) antes.
Ficou um contêiner rodando	Rode docker ps --filter name=llama-desktop-vllm- e docker stop NOME.
Clientes da rede não conectam	A regra automática de firewall não vale para o Docker; crie a regra manual do Guia de integração.
“O número de GPUs (N) precisa dividir as … cabeças de atenção do modelo.”	Escolha um paralelismo de tensor que divida o número de cabeças (1, 2, 4…).
Autotuning do vLLM: a tentativa com fp8 falha	A GPU não aceita cache KV fp8; a tentativa é descartada.
Autotuning do vLLM demora muito	Cada tentativa recarrega o modelo e captura os CUDA graphs. Escolha 20 ou 30 minutos, ou ajuste à mão depois da sugestão inicial.

O vLLM pode levar vários minutos na primeira carga. O launcher espera até 30 minutos antes de mostrar “Tempo esgotado ao carregar o modelo.”.

7. Strata e PolyStrata

Sintoma	Causa provável e solução
“A pasta precisa ser uma instalação do Strata ou do PolyStrata já configurada…”	Escolha a raiz da instalação, que contém serve/server.py e .venv. Se .venv não existir, rode o START-HERE.bat ou o setup.sh deles até o fim.
A pasta é aceita, mas nenhum modelo aparece	O launcher lê só os strata-*.json da raiz da pasta, ignora *.shared-settings.json, arquivos acima de 1 MB e JSON inválido. Configure um modelo pelo instalador deles.
As sessões simultâneas não mudam nada	No PolyStrata vale o parallel da configuração dele; altere por lá.
O servidor encerra ou não fica pronto	Veja o registro: em geral os pesos não foram baixados, a GPU não é suportada ou falta memória. Teste o servidor pelo próprio projeto para isolar o problema.
“Não foi possível localizar o Python base do Strata / PolyStrata (pyvenv.cfg)…”	O .venv não aponta para um Python existente. Recrie o ambiente pelo instalador deles ou libere a porta manualmente no firewall.
O cliente diz que o modelo não existe	Use o **Modelo API** do painel (o model_name da configuração), não modelo-local. Copie a configuração de novo.
Campo do Strata desativado com “A versão instalada … não aceita --…”	O serve/server.py instalado não tem essa opção. Atualize pelo instalador do projeto.

8. Rede, chaves e firewall

Sintoma	Causa provável e solução
O endereço LAN ou Tailscale não aparece na lista	Só endereços privados IPv4 e Tailscale (100.64.0.0/10) são listados. Confira se o Tailscale está conectado e reabra o launcher.
Funciona neste PC, mas não em outro	Firewall, IP errado ou outra rede. Teste GET /v1/models do outro computador (exemplos no Guia de integração).
“Acesso negado: chave ou token de sessão local ausente ou inválido.”	A página da ponte local foi aberta sem o token. Use **Abrir no navegador** de novo.
“Acesso compartilhado ausente, expirado ou revogado.”	O link com acesso é de uma execução anterior ou foi revogado. Copie um novo.
401 na porta direta	Chave errada ou trocada com **Nova chave**. Copie a chave atual.
“A faixa de clientes precisa conter o endereço da rede selecionada.”	Use uma faixa que inclua o IP do servidor, como 192.168.1.0/24 para 192.168.1.5.
“O endereço remoto deve ficar dentro de uma rede LAN privada ou Tailscale.”	A regra só aceita 10/8, 172.16/12, 192.168/16 ou 100.64/10.
“As regras não foram removidas: a autorização de administrador foi negada…”	O pedido de administrador foi negado ou fechado. Clique de novo em **Remover regras do launcher** e confirme.
A regra de firewall não é criada	O pedido de administrador foi negado ou fechado. Clique de novo e confirme.
Regras antigas continuam liberadas	As regras LlamaDesktopLauncher-… ficam no Windows depois que o servidor para. No Strata/PolyStrata elas liberam o python.exe do sistema, usado por qualquer programa Python. Use **Configurações > 07 · Firewall do Windows > Remover regras do launcher**, o wf.msc ou, em um PowerShell como administrador, Get-NetFirewallRule -Name 'LlamaDesktopLauncher-*' | Remove-NetFirewallRule.
“ID de modelo inválido.” ao copiar	O model_name do Strata está vazio, tem mais de 128 caracteres, começa com - ou contém quebra de linha ou outro caractere de controle. Espaços e símbolos são aceitos. Corrija o nome na configuração strata-*.json.

9. Atualizações

Sintoma	Causa provável e solução
“Você já usa a versão mais recente”, mas existe uma nova	A verificação roda ao abrir e uma vez por dia. Clique em **Verificar agora**.
A verificação falha	Sem acesso a api.github.com (rede, proxy ou limite de pedidos). Tente mais tarde ou baixe pela página de releases.
“Esta versão não tem pacote para este sistema.”	A release não tem instalador para a sua plataforma. Use as notas da versão para baixar outro formato.
“SHA256SUMS.txt não lista o pacote…” / “Checksum … não confere”	O pacote foi apagado por segurança. Tente de novo; se repetir, relate o problema.

10. Mensagens do aplicativo

Mensagem	Significado
“Pare a execução atual antes de iniciar outra.”	Já existe um servidor, uma conversa, um teste ou uma preparação de motor.
“Instale ou selecione o llama.cpp primeiro.”	O modelo é GGUF e o llama.cpp não está pronto.
“Prepare o vLLM em Configurações primeiro.”	Falta instalar o vLLM (Linux) ou baixar a imagem (Windows).
“Escolha a pasta do Strata ou do PolyStrata em Configurações primeiro.”	O modelo é do Strata, mas a pasta não está configurada ou não é mais válida.
“… está disponível só para modelos GGUF no llama.cpp.”	Conversa integrada, CLI, análise e valores automáticos (llama-fit-params) existem só no llama.cpp.
“O Strata e o PolyStrata não têm autotuning…”	Quantização, contexto e GPU vêm da configuração do instalador deles.
“Já existe um teste em execução.”	Aguarde ou clique em **Cancelar** no autotuning.
“Modelo não encontrado nas pastas configuradas.”	O arquivo foi movido ou a pasta mudou. Atualize a lista.
“Escolha um endereço de rede disponível.”	O IP escolhido não existe mais (rede trocada). Escolha de novo.
“Pare o servidor antes de gerar outra chave.”	A chave não pode mudar com o servidor ativo.
“Inicie o servidor em LAN ou Tailscale para compartilhar.”	O compartilhamento não existe no acesso local.
“Chave de API inválida. Gere uma nova chave.”	O server-api-key.txt foi alterado. Use **Nova chave**.
“O vLLM no Docker escuta pelo Docker Desktop…”	A regra automática não vale para o Docker; crie a regra manual.
“Escolha uma pasta fora da instalação do aplicativo…”	A desinstalação apagaria essa pasta.

11. Antes de abrir uma issue

- Atualize para a versão mais recente e repita o problema.

- Reproduza com o modelo menor possível e as configurações padrão.
- Copie o relatório de diagnóstico logo depois da falha, antes de fechar o launcher.
- Revise o relatório e tire o que for pessoal.
- Descreva o passo a passo, o resultado esperado e o que aconteceu.